

Aula 10: Tendências do Gerenciamento de Configuração

Apresentação

Nesta aula focaremos em mais um tópico avançado relacionado à Gerência de Configuração; no caso, suas tendências atuais e futuras.

Objetivos

- Examinar a visão geral de Inteligência Artificial;
- Identificar o emprego da AI na Gerência de Configuração;
- Analisar as vantagens e desvantagens do emprego da AI na gerência de configuração.

A Inteligência Artificial – Pode um Computador Aprender e Pensar?

Atualmente muito se fala em Inteligência Artificial (IA) e seus impactos revolucionários no mundo moderno. De fato, a IA está se tornando ubíqua, passando a incorporar e a melhorar várias utilidades e aplicações que há cinco ou 10 anos já existiam, e, até onde podíamos julgar na época, funcionavam bem o suficiente.


A AI, com seu rápido avanço, tomou o mundo de surpresa, e forçou e continuará a forçar a reconsideração rápida de paradigmas outrora bem estabelecidos, já que ignorar essa tendência e evitar sua adoção irá ser cada vez mais fonte de desvantagem em relação aos competidores.

Comentário

Embora a ideia por trás da IA pareça ser algo muito moderno, a verdade é que, para entendermos o conceito de IA, precisamos voltar aos anos 1950, logo após a Segunda Guerra Mundial. Foi nessa época que o famoso cientista de computação Alan Turing estabeleceu a visão e objetivos gerais do que conhecemos hoje como Inteligência Artificial.

De maneira simplificada, Turing se perguntava se seria possível que máquinas viessem a pensar.

É claro que ao longo das décadas essa pergunta nada trivial (em especial se considerarmos o nível de avanço tecnológico encontrado nos anos 1950) passou por muitas reformulações à medida que diferentes pesquisadores e cientistas se debruçavam sobre o tema, sob diferentes perspectivas e diferentes objetivos.




 Fonte: Pexels

Apesar das reformulações, a pergunta fundamental permaneceu a mesma, sendo que a definição abaixo captura bem o estado da arte atual:

“IA é um sistema de computador capaz de realizar tarefas que requerem inteligência humana ordinária.... Muitos desses sistemas são habilitados por aprendizado de máquina, alguns destes sistemas são habilitados por aprendizado profundo e alguns deles são habilitados por coisas chatas, como por exemplo regras.”

- Jeremy Achin, CEO da empresa DataRobot

Para que esta definição comece a fazer sentido, é importante entender que sistemas de IA são inseridos em duas categorias macro:

 Clique nos botões para ver as informações.

Inteligência Artificial Estrita



Também chamada de IA Fraca, fornece capacidades de inteligência em um contexto limitado, sendo uma simulação da inteligência humana. Geralmente se foca em uma única tarefa, que procura-se executar de forma otimizada. Apesar disso, não é possível comparar a inteligência de máquina com a inteligência humana, pois a primeira opera sob restrições e limitações muito mais numerosas do que a mais básica inteligência humana.

Inteligência Artificial Geral



Também chamada de IA Forte, é o tipo de inteligência propagada por Hollywood, do tipo possuído pelos Cylons na série *Battlestar Galactica*, ou pelo T-800 nos filmes do *Exterminador do Futuro*. Essas máquinas possuem inteligência geral, e podem aplicá-la para resolver quase qualquer tipo de problema.

Dadas essas definições, não é preciso ser técnico para perceber que o tipo de IA que, ao menos no momento, está se tornando ubíqua é a *IA Fraca*. É nesse tipo de IA que iremos focar, afinal é o tipo que atualmente é amplamente viável de ser adotado, dadas as limitações tecnológicas de nossa era.

Isso não quer dizer que não existam avanços no campo da IA forte, significa apenas que levará mais tempo até que a IA forte possa se tornar prática a ponto de se tornar ubíqua e relevante o suficiente para nossa sociedade.

Inteligência Artificial Estrita

As conquistas trazidas pela Inteligência Artificial Estrita são facilmente reconhecíveis como as maiores realizações e contribuições advindas do campo da IA para o mundo atual. De fato, inúmeras descobertas na última década geraram significativos avanços na sociedade como um todo. Vejamos alguns exemplos dessas conquistas e avanços.

Assistentes inteligentes, tais como Siri, Alexa e Google.	Ferramentas de mapeamento e predição de doenças.	Robôs empregados em manufatura.
Drones.	Recomendações personalizadas (filmes, músicas, compras, tratamentos, rotas etc.).	Robôs para atendimento (via voz ou via texto).
Robôs para a comercialização de ações de bolsas de valores.	Filtros anti-spam avançados em e-mail.	Anti-vírus avançados.
Ferramentas de monitoração em redes sociais.	Veículos autônomos.	Reconhecimento de imagem e voz.

Esses muitos avanços proporcionados pela IA estrita derivam de outros tantos avanços no campo da ciência da computação, mais precisamente nos subcampos do Aprendizado de Máquina (*Machine Learning*) e Aprendizado Profundo (*Deep Learning*). O Aprendizado de Máquina em si veio antes do Aprendizado Profundo, embora o último faça intenso uso de Redes Neurais, que, curiosamente, como conceito, vieram antes do próprio Aprendizado de Máquina.



Um ponto muito importante a ser ressaltado é que a matéria-prima para o funcionamento de ambos os paradigmas são dados, muitos dados. A analogia a seguir captura bem o que isso significa na prática:

“A IA é como se fosse um foguete. Nela, os algoritmos são o motor enquanto o combustível é representado pelas enormes quantidades de dados necessários para alimentar estes algoritmos. Se você tem um motor grande, mas pouco combustível, você não chegará à órbita. Se você tem um motor pequeno, mas uma tonelada de combustível, não sai nem do chão. Para construir um foguete você precisa de um motor enorme e de muito combustível.”

- Andrew Ng, Cientista de Dados da plataforma Baidu

É comum que, em um momento que anteceda a adoção da Inteligência Artificial, esses dados estejam disponíveis, mas sejam dados “sujos”, ou seja, dados muitas vezes manualmente inseridos e espalhados em diversos bancos de dados, com diversos formatos e diversos níveis de granularidade. Em outras palavras, existe variação demais na qualidade dos dados.

Dica

É preciso que alguém “limpe estes dados”, ou seja, dê sentido a eles, os reorganize, os normalize, por exemplo, os convertendo para um formato comum e/ou exportando-os para um sistema / banco de dados comum. Esse é um dos trabalhos dos cientistas de dados.

Como se deve imaginar, por envolver tanto fontes legadas como fontes novas de dados, as legadas sem muitas vezes sequer possuírem documentação adequada, isto pode ser um trabalho hercúleo, uma montagem de quebra-cabeças, que requer muito tempo e esforço.

Caso dados suficientes não estejam disponíveis, processos automatizados de coleta de dados de diversas fontes e sistemas podem ser esquematizados para acelerar o processo.

Se for esse o caso, esses próprios processos de coleta já podem ser concebidos para limpar, ao menos em parte, os dados, o que liberaria um pouco mais de tempo dos cientistas e engenheiros para focarem na seleção de características (*features*) dos dados. Essas *features* são necessárias para que a tarefa de Inteligência Artificial possa ser criada.

Quando a situação dos dados se encontrar largamente resolvida, os cientistas de dados e/ou engenheiros de IA passam a focar na criação dos modelos de IA, que são de fato a codificação dos algoritmos, ou instruções necessárias para que a tarefa de Inteligência Artificial possa ocorrer.

Uma vez criados, esses modelos ou programas são “treinados” com base nos dados disponíveis, de forma a aprenderem as correlações entre as diversas características desses dados em uso.

Uma vez que essas correlações tenham sido estabelecidas, o modelo encontra-se treinado, podendo então fazer inferências do tipo X resulta em Y. O modelo está então pronto para a fase de testes ou implantação, ou seja, a fase em que passa a receber novos dados nunca vistos durante a fase de treinamento, podendo agora predizer resultados com base nas inferências que aprendeu.

Agora sim podemos focar em entender a diferença entre Aprendizado de Máquina e Aprendizado Profundo.

Atenção! Aqui existe uma videoaula, acesso pelo conteúdo online

Aprendizado de Máquina

O Aprendizado de Máquina é considerado Inteligência Artificial do tipo tradicional. Ser tradicional significa que os algoritmos que a implementam requerem muita intervenção humana para a seleção das características (*features*) apropriadas para um treinamento eficiente e eficaz.

Não somente isso, requerem mais intervenções durante o próprio treinamento, por exemplo, no caso de uma inferência não ser boa o bastante, devendo o cientista de dados intervir para que melhores inferências sejam atingidas.

Em outras palavras, o Aprendizado de Máquina tem a desvantagem de exigir forte conhecimento de domínio por parte do cientista de dados para que seja eficaz com relação à tarefa de interesse. Exemplos desses algoritmos são:

Árvores de decisão;

Máquinas de suporte vetorial;

Rede Bayesiana;

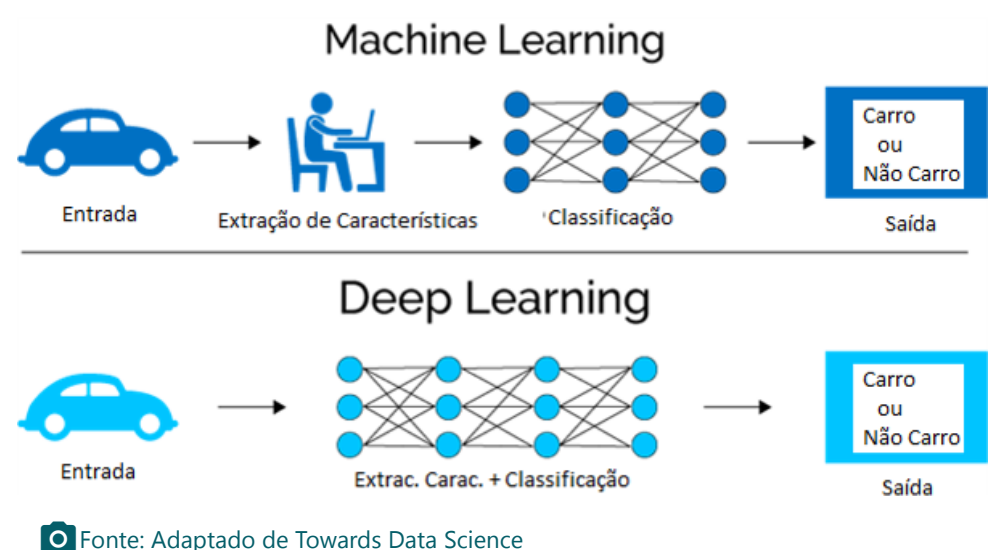
K-Vizinhos Mais Próximos.

Aprendizado Profundo

O aprendizado profundo gira ao redor da aplicação de redes neurais. Esses algoritmos foram inspirados e lembram fracamente a forma como o cérebro humano funciona, com seus vários neurônios individuais conectados entre si. O termo profundo, aliás, vem do uso de múltiplas camadas de neurônios interconectadas, ou seja, “camadas profundas”.

A razão para existência dessa arquitetura é relativamente simples de entender (embora não sejam simples de implementar): a aplicação de princípios estatísticos para aprendizado automatizado.

Diferenças entre Aprendizado de Máquina (ML) e Aprendizado Profundo (DL)



O termo automatizado aqui se refere à drástica redução da necessidade por intervenção manual na seleção de características e treinamento dos modelos. As inferências vão melhorando sozinhas, à medida que o treinamento avança, graças a esta arquitetura baseada em princípios estatísticos.

Essas facilidades são exatamente o que está por trás do massivo ganho de popularidade da Inteligência Artificial via aprendizado profundo nos últimos anos, substituindo o Aprendizado de Máquina em vários domínios.

Exemplos desses algoritmos são:


Redes Neurais Convolucionais;

Redes Neurais Recorrentes;

Redes Neurais Modulares.

Como conclusão e resposta à pergunta do início sobre se um computador pode aprender, fica claro aqui que o aprendizado atual na verdade se trata de ter acesso a muitos dados e encontrar correlações matemáticas entre as características destes dados - por exemplo, a correlação entre sobrepeso (X) e a ocorrência de doenças (y).

Após a identificação dessa correlação, toda vez que o computador vir dados novos que sigam esse padrão, poderá, portanto, realizar inferências com base no que aprendeu previamente.



Exemplo de uma Rede Neural Convolucional Usada para Identificar Imagens. Fonte: Adaptado de Javatpoint

Veja alguns exemplos de casos práticos de uso de Inteligência Artificial.

Caso de Uso Prático de Inteligência Artificial Número 1

PREDIZER uma saída baseando-se em dados atuais e históricos.

Exemplo: Uso de dados sensoriais em tempo real de um motor para prever qual é a sua vida útil restante.

Aplicações: Manutenção preventiva, sistemas financeiros, sistemas de recomendação.

Entrada: Dados sensoriais, dados financeiros com data e hora, dados numéricos.

Caso de Uso Prático de Inteligência Artificial Número 2

RESPONDER a comandos de voz ou texto baseando-se em contexto e rotinas.

Exemplo: Reconhecer comandos do tipo “Ligar”, “Desligar”, “Esquerda”, “Direita”.

Aplicações: Relacionamento com cliente, dispositivos inteligentes, assistentes digitais, tradução etc.

Entrada: Dados acústicos, dados textuais.

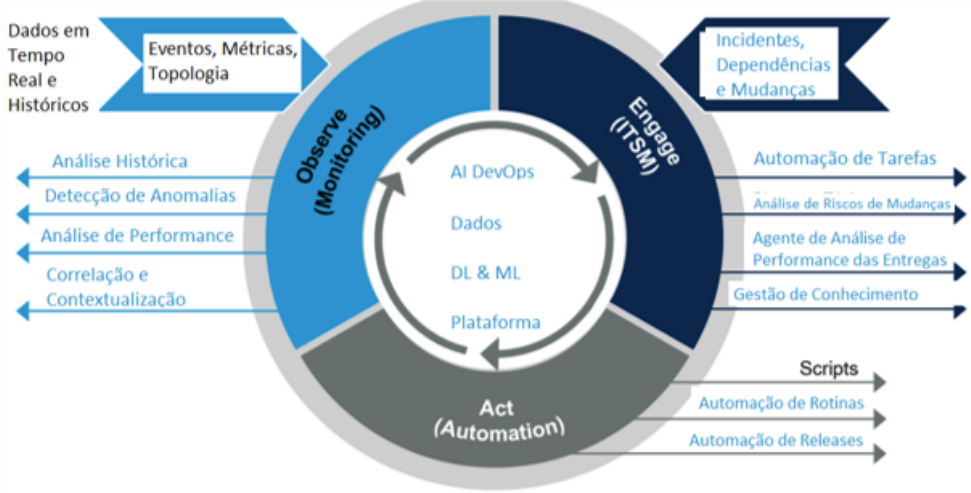
O emprego da AI na Gerência de Configuração – AI DevOps

Agora que entendemos melhor do que trata a Inteligência Artificial, podemos voltar ao assunto da Gerência de Configuração. Como ocorre em qualquer domínio, a Gerência de Configuração também pode se beneficiar diretamente da Inteligência Artificial.

Aliás, com base no que vimos até então, fica claro que a Gerência de Configuração é um campo fértil para aplicação da IA, o que tem ocorrido principalmente por sua penetração em ao menos um segmento específico – o DevOps.

Visto que o DevOps opera sobre a premissa do uso intenso de automação, gerando um grande volume de dados, é possível empregar IA em uma série de atividades do DevOps, voltando-a para o aprendizado de padrões, antecipação de problemas e até mesmo para a sugestão de que curso de ação tomar em cada situação. O DevOps e a IA se tornam, portanto, interdependentes, surgindo assim o novo conceito *DevOps com AI* ou *AI DevOps*.

Plataforma AI DevOps Para Descobertas Contínuas Por Meio de Monitoração.



📷 Fonte: Adaptado de Gartner

Atenção! Aqui existe uma videoaula, acesso pelo conteúdo online

Vamos conhecer agora as vantagens do AI DevOps sobre o DevOps Convencional.

📄 Conceitos habilitadores dos sistemas de controle de versão

👉 Clique no botão acima.

Conceitos habilitadores dos sistemas de controle de versão

Vejamos a seguir algumas vantagens atuais, bem como possibilidades futuras, abertas pelo emprego da IA no DevOps:

- Promoção de Feedback sobre Performance

Como foi visto anteriormente, um dos pontos-chave do DevOps é o uso de ciclos contínuos de feedback a cada estágio. Isso inclui ferramentas de monitoração para prover sobre a performance operacional das aplicações em serviço. Esse é um ponto que a IA já é capaz de impactar fortemente em DevOps.

Plataformas de monitoração agregam quantidades massivas de dados em forma de métricas, logs, matrizes, planilhas e outros formatos. Essas plataformas estão evoluindo por meio da aplicação de IA a esses dados para identificar problemas de maneira proativa o mais cedo possível, gerando recomendações.

Tais recomendações são enviadas aos membros do time para que assegurem que cada aplicação se mantenha viável e valorosa por meio de ajustes e modificações.

Esses mesmos dados podem ainda ser fontes de colaboração maior entre equipes de desenvolvimento e operações, pois a AI dá contexto a eles, provendo uma visão única dos sistemas e de seus problemas através da cadeia do DevOps. Assim melhora o entendimento e conhecimento de anomalias detectadas, auxiliando nas suas retificações.

- Habilitação de Melhor Comunicação

Para canais de comunicação que não exigem comunicação com recursos humanos escassos, tecnologias de IA automatizadas como chatbots podem ser uma das soluções a serem empregadas.

- Fazer a Correlação de Dados entre Múltiplas Plataformas e Ferramentas

Embora as equipes de DevOps desejem simplificar tarefas, nem sempre isso é possível já que os ambientes estão ficando mais complexos. Ferramentas de monitoração normalmente são empregadas para facilitarem até certo ponto essa tentativa de simplificação, pois observam a saúde de performance dos aplicativos de diferentes maneiras, gerando muitos fluxos contínuos de dados.

A IA pode absorver esses fluxos e estabelecer correlações entre eles, dando uma visão mais holística da saúde destes aplicativos.

- Gerenciar a Avalanche de Alertas

Um dos mantras do DevOps é “falhe mas falhe rápido”. Para que isso funcione, é necessário que sistemas de monitoração alertem para falhas rapidamente. Isso pode gerar cenários em que muitos alertas vêm rápido e furiosamente, todos com o mesmo nível de criticidade, dificultando a reação das equipes.

A IA pode ser usada para ajudar as equipes a priorizarem as suas respostas, por meio da identificação de padrões baseados em comportamento passado, a magnitude do alerta atual e a fonte específica do alerta. Humanos podem definir regras, mas as máquinas ajudam na gestão das situações em que dados demais sobrecarregam o sistema.

- Avaliar Performance Passada

A IA tem o potencial de ajudar desenvolvedores durante a criação da aplicação. Ao examinar o sucesso de aplicações passadas em termos de sucesso em relação à construção/compilação, teste e performance operacional, algoritmos de IA podem vir a fazer recomendações proativas a desenvolvedores com base no código que estão escrevendo.

O motor de IA pode vir a direcionar o desenvolvimento em uma aplicação de forma mais eficiente e com maior qualidade possível.

- Teste de Software

A IA tem o potencial de ser empregada nos testes de software, já que testes unitários, de regressão, funcionais e de aceitação produzem muitos dados na forma de resultados de teste. A IA pode vir a identificar padrões de práticas pobres de codificação, o que leva a muitos erros encontrados pelos testes. Essa informação pode ser retroalimentada às equipes responsáveis, tornando-as mais eficientes.

- Melhor Previsão de Falhas

A IA tem habilidade de ler padrões e prever sinais de falha, especialmente quando se sabe que uma determinada falha produz leituras claras e específicas. A IA vê indicadores mínimos que humanos normalmente não percebem. Tal percepção pode ajudar as equipes a identificarem e consertarem problemas antes que impactem no ciclo de vida dos aplicativos.

- Melhor Gestão de Recursos

Já está claro que a IA fornece as capacidades para automatizar tarefas rotineiras e repetitivas. Conforme a IA amadurece, o escopo e complexidade destas tarefas que podem ser automatizadas só irá aumentar, e as organizações e os humanos poderão obter ainda mais vantagens por meio da IA, focando mais nas tarefas que exigem criatividade.

- Análise de Causa-Raiz Mais Rápida

Engenheiros muitas vezes estão mais preocupados em manter tudo rodando do que identificar causas raízes de falhas. A IA é capaz de usar padrões encontrados entre causa e atividade para determinar justamente qual é a causa raiz por trás de uma falha. Isto é importante para que as ações não sejam somente superficiais, e, portanto, levem ao conserto permanente.

As Desvantagens do AI DevOps

Embora poucas se comparadas com as vantagens, não é possível ignorar possíveis desvantagens que o emprego da IA pode trazer ao DevOps, tais como:

- Distrações geradas pelo aspecto “artificial”

Uma das críticas negativas acerca da AI DevOps é que ela possivelmente distrai os times de engenharia do objetivo final. Isso porque, como já vimos, a IA possível de ser aplicada no momento é a IA fraca, que basicamente faz inferências baseadas em estatística e poder computacional aplicado a uma tarefa específica. Embora isso seja sim útil às organizações, quando se tem uma TI fragilizada, é importante manter as perspectivas no lugar certo.

Comentário

Isso significa não procurar robotizar todos os aspectos possíveis da produção de software como se fosse a “bala de prata”. A IA não substitui a necessidade de pensar em como melhorar os sistemas e processos, investir na formação de times autônomos e autossuficientes, anotar *frameworks* ágeis, criar um ambiente propício ao progresso e melhoria contínua.

Em outras palavras, humanos ainda precisam estar na vanguarda, e isso continuará assim por muito tempo.

- Adoção Ainda mais Complicada

“O DevOps não é doloroso o bastante”. Essa frase de um consultor de tecnologia define bem o dilema que a adoção da IA, em conjunto com o DevOps, traz às organizações.

Aplicações habilitadas por IA requerem mais do que dados, necessitando ainda de desenvolvedores que dominam as ferramentas e habilidades da ciência de dados. Além disso, precisam de computação de alta-performance, fluxos de trabalho complexos e práticas a nível organizacional.

Isso se soma aos requisitos já extensos do próprio DevOps. Além disso, as organizações evoluem, e isso também acontece com seus projetos e operações. Assim, os modelos de IA precisam ser constantemente revalidados e retreinados usando dados novos vindos do ciclo de vida das aplicações. Tudo isso exige esforço, recursos e foco constantes.

Atenção! Aqui existe uma videoaula, acesso pelo conteúdo online

Atividades

1. O DevOps com IA:

- a) Gera alertas demais.
 - b) Gera alertas de menos.
 - c) Dificulta a gestão de alertas.
 - d) Facilita a gestão de alertas.
 - e) Não muda nada em relação aos alertas.
-

2. O Profundo em Aprendizado Profundo vem de onde?

- a) Dos muitos algoritmos baseados em redes neurais usados.
 - b) Dos muitos dados usados pelas redes neurais.
 - c) Das muitas camadas das redes neurais.
 - d) Das muitas tecnologias empregadas em redes neurais.
 - e) Não tem ligação com redes neurais.
-

3. A fase ou passo marcado pela interrogação diz respeito a:

- a) Classificação.
 - b) Distribuição.
 - c) Regressão.
 - d) Extração.
 - e) Extração e Classificação.
-

4. Não é um exemplo de IA tradicional:

- a) Árvores de decisão.
- b) Rede Bayesiana.
- c) Máquinas de Suporte Vetorial.
- d) Redes Neurais.
- e) K-Vizinhos Mais Próximos.

5. É a matéria prima da IA. Estamos falando de:

- a) Informação.
- b) Conhecimento.
- c) Configuração.
- d) Dados.
- e) Pessoas.

Notas

Título modal ¹

Lorem Ipsum é simplesmente uma simulação de texto da indústria tipográfica e de impressos. Lorem Ipsum é simplesmente uma simulação de texto da indústria tipográfica e de impressos. Lorem Ipsum é simplesmente uma simulação de texto da indústria tipográfica e de impressos.

Título modal ¹

Lorem Ipsum é simplesmente uma simulação de texto da indústria tipográfica e de impressos. Lorem Ipsum é simplesmente uma simulação de texto da indústria tipográfica e de impressos. Lorem Ipsum é simplesmente uma simulação de texto da indústria tipográfica e de impressos.

Referências

The Ultimate DevOps Playbook. Disponível em: <https://www.bmc.com/blogs/what-is-aiops/>. Acesso em 11 nov. 2020.

Market Guide for AIOps Platforms. Disponível em: www.gartner.com. Acesso em 11 nov. 2020.

How to Get Started with AIOps. Disponível em: www.gartner.com. Acesso em 11 nov. 2020.

Artificial Intelligence What it is and why it matters. Disponível em https://www.sas.com/en_us/insights/analytics/what-is-artificial-intelligence.html. Acesso em 11 nov. 2020.

10 Ways AI is Accelerating DevOps. Disponível em: <https://www.forbes.com/sites/louiscolumbus/2020/07/31/10-ways-ai-is-accelerating-devops/#1fcd9b556a50>. Acesso em 11 nov. 2020.

CNN Architectures, a Deep-dive. Disponível em: <https://towardsdatascience.com/cnn-architectures-a-deep-dive->

Próxima aula

Explore mais

- Acesse o artigo “O que Machine Learning pode aprender com DevOps” publicado no site InfoQ.